



## TRABALHO - IDENTIFICAÇÃO DE SISTEMAS

Raphael Timbó Silva

Professor: Daniel Castello

Rio de Janeiro  
Janeiro de 2017

# Sumário

<b>Lista de Figuras</b>	<b>b</b>
<b>Lista de Tabelas</b>	<b>c</b>
<b>Lista de Abreviaturas</b>	<b>d</b>
<b>1 Introdução</b>	<b>1</b>
1.1 Sistema utilizado . . . . .	1
1.2 Resposta do sistema . . . . .	2
<b>2 Dados Pseudo-Experimentais</b>	<b>4</b>
2.1 Resposta do sistema no tempo . . . . .	4
2.2 Adição do ruído . . . . .	8
<b>3 Projeto do Filtro Adaptativo</b>	<b>10</b>
3.1 Algoritmo LMS . . . . .	10
3.2 Implementação do filtro . . . . .	12
<b>4 Resultados e Discussões</b>	<b>14</b>
<b>5 Conclusões</b>	<b>15</b>
<b>Referências Bibliográficas</b>	<b>16</b>
<b>A Algumas Demonstrações</b>	<b>17</b>

# Lista de Figuras

1.1	Sistema utilizado na análise. . . . .	1
1.2	FRF para o sistema em análise. . . . .	3
1.3	Aplicação de força e medição na massa $m_2$ . . . . .	3
1.4	FRF para input em $m_2$ e medição em $m_2$ . . . . .	3
2.1	Frequência de excitação para a força $F_0$ . . . . .	5
2.2	Resposta no tempo para a força $F_0$ com $N = 1000$ . . . . .	5
2.3	Resposta no tempo para a força $F_0$ com $N = 5000$ . . . . .	6
2.4	Frequência de excitação para a força $F_1$ . . . . .	7
2.5	Resposta no tempo para a força $F_1$ com $N = 5000$ . . . . .	7
2.6	Resposta no tempo para a força $F_2$ com $N = 5000$ . . . . .	8
2.7	Sinal puro e sinal corrompido para $F_0$ e $SNR = 90$ . . . . .	9
2.8	Sinal puro e sinal corrompido para $F_0$ e $SNR = 10$ . . . . .	9
2.9	Sinal puro e sinal corrompido para $F_2$ e $SNR = 10$ . . . . .	9
3.1	Configuração utilizada no algoritmo para filtros adaptativos. . . . .	10

# Lista de Tabelas

# Lista de Abreviaturas

FIR	Finite Impulse Response, p. 1
FRF	Função de Resposta em Frequência, p. 2
SNR	Signal to Noise Ratio, p. 4

# Capítulo 1

## Introdução

O presente trabalho tem por objetivo apresentar os resultados e conclusões referentes ao projeto final da disciplina Identificação de Sistemas.

O trabalho consiste na análise de um sistema através do projeto de um filtro adaptativo FIR (Finite Impulse Response).

### 1.1 Sistema utilizado

O sistema utilizado é mostrado na fig. 1.1.




Figura 1.1: Sistema utilizado na análise.

Para este sistema temos que a energia cinética é:

$$T = \frac{1}{2}[m_0\dot{q}_0(t)^2 + m_1\dot{q}_1(t)^2 + m_2\dot{q}_2(t)^2] = \frac{1}{2}\dot{\mathbf{q}}^T(t)M\dot{\mathbf{q}}(t) \quad (1.1)$$

onde

$$\mathbf{q}(\mathbf{t}) = [q_0(t) \ q_1(t) \ q_2(t)]^T$$

é o vetor de configuração e

$$M = \begin{bmatrix} m_0 & 0 & 0 \\ 0 & m_1 & 0 \\ 0 & 0 & m_2 \end{bmatrix}$$

é a matriz de massa do sistema.

A energia potencial tem a expressão:

$$\begin{aligned} V &= \frac{1}{2}[k_0 q_0(t)^2 + k_1(q_1(t) - q_0(t))^2 + k_2 q_2(t)^2] \\ &= \frac{1}{2}[(k_0 + k_1)q_0(t)^2 + (k_1 + k_2)q_1(t)^2 + (k_2)q_2(t)^2 - 2k_1 q_0(t)q_1(t) - 2k_2 q_2(t) \\ &= \frac{1}{2}\dot{\mathbf{q}}^T(t)K\dot{\mathbf{q}}(t) \end{aligned} \tag{1.2}$$

onde

$$K = \begin{bmatrix} k_0 + k_1 & -k_1 & 0 \\ -k_1 & k_1 + k_2 & -k_2 \\ 0 & -k_2 & k_2 \end{bmatrix}$$

é a matriz de rigidez do sistema.

Para o sistema utilizado temos que  $m_i = 1 \text{ kg}$  e  $k_i = 1600 \text{ N/m}$ .

O amortecimento utilizado será o proporcional:  $C = \alpha M + \beta K$ . Iremos analisar o caso em que  $\alpha = 10^{-3}$  e  $\beta = 10^{-3}$ .

## 1.2 Resposta do sistema

O sistema em questão possui a resposta FRF (Função de Resposta em Frequência) apresentada na fig. 1.2

Para nossa análise iremos considerar uma força aplicada na massa 2 ( $m_2$ ) e a medição nesta mesma massa, conforme ilustrado na fig. 1.3. A aplicação da força nessa massa corresponde à FRF que pode ser visualizada no canto inferior direito (input=2 e output=2). A FRF em questão é também mostrada na fig. 1.4




Figura 1.2: FRF para o sistema em análise.




Figura 1.3: Aplicação de força e medição na massa  $m_2$ .




Figura 1.4: FRF para input em  $m_2$  e medição em  $m_2$ .



# Capítulo 2

## Dados Pseudo-Experimentais

### 2.1 Resposta do sistema no tempo

Para a construção dos dados pseudo-experimentais foram observados os seguintes casos:

Forçamento:

- $F_0(t) = A_0 \sin(2\pi f_0 t)$  (Considere  $\frac{\omega_1}{2\pi} \leq f_0 \leq \frac{\omega_2}{2\pi}$ )
- $F_1(t) = A_1 \sin(2\pi f_1 t) + A_2 \sin(2\pi f_2 t)$  (Escolha  $\frac{0.8\omega_1}{2\pi} \leq f_j \leq \frac{1.2\omega_2}{2\pi}$  e  $A_2 = 2A_1$  ;  $j = 1, 2$ )
- $F_2(t) = \text{ruído branco}$

Número de amostras  $N$ :

- $N = 1000$
- $N = 5000$

Valores para a relação entre sinal e ruído - SNR (Signal to Noise Ratio):

- $SNR = 90$
- $SNR = 50$
- $SNR = 10$

A fig. 2.1 mostra a posição da frequência de excitação para a aplicação da força  $F_0$ , em que uma amplitude  $A_0 = 1$  foi utilizada.

A fig. 2.2 mostra a resposta no tempo do sistema ao aplicarmos a força  $F_0$  na frequência mostrada na fig. 2.1 para uma amostragem  $N = 1000$ . Podemos observar que, para  $N = 1000$ , temos uma excitação de aproximadamente 16 segundos e ainda




Figura 2.1: Frequência de excitação para a força  $F_0$ .




Figura 2.2: Resposta no tempo para a força  $F_0$  com  $N = 1000$ .




Figura 2.3: Resposta no tempo para a força  $F_0$  com  $N = 5000$ .

temos algum transiente na resposta no tempo. Também é possível observar que essa parcela apresenta mais que uma frequência de oscilação.

A fig. 2.3 mostra a resposta no tempo para  $N = 5000$ . Neste caso, o tempo vai até aproximadamente 80 segundos e podemos observar que a parcela transiente é praticamente inexistente após os 20 segundos de excitação. Após esse tempo, é esperado que o sistema oscile apenas na frequência de excitação.

Para a força  $F_1$  a fig. 2.4 mostra as frequências de excitação que foram aplicadas na massa  $m_2$ . Podemos notar que nesse caso as forças aplicadas estão próximas as frequências naturais do sistema.

A fig. 2.5 mostra a resposta no tempo para  $F_1$  com  $A_1 = 1$ ,  $A_2 = 2$  e  $N = 5000$ . Como esperado, notamos um aumento na amplitude de  $1 \times 10^{-3}$  m para  $1 \times 10^{-2}$  m quando comparado à força  $F_0$ .

O último caso de forçamento é mostrado na fig. 2.6 onde um ruído branco com variância 1 é aplicado ao sistema.




Figura 2.4: Frequência de excitação para a força  $F_1$ .

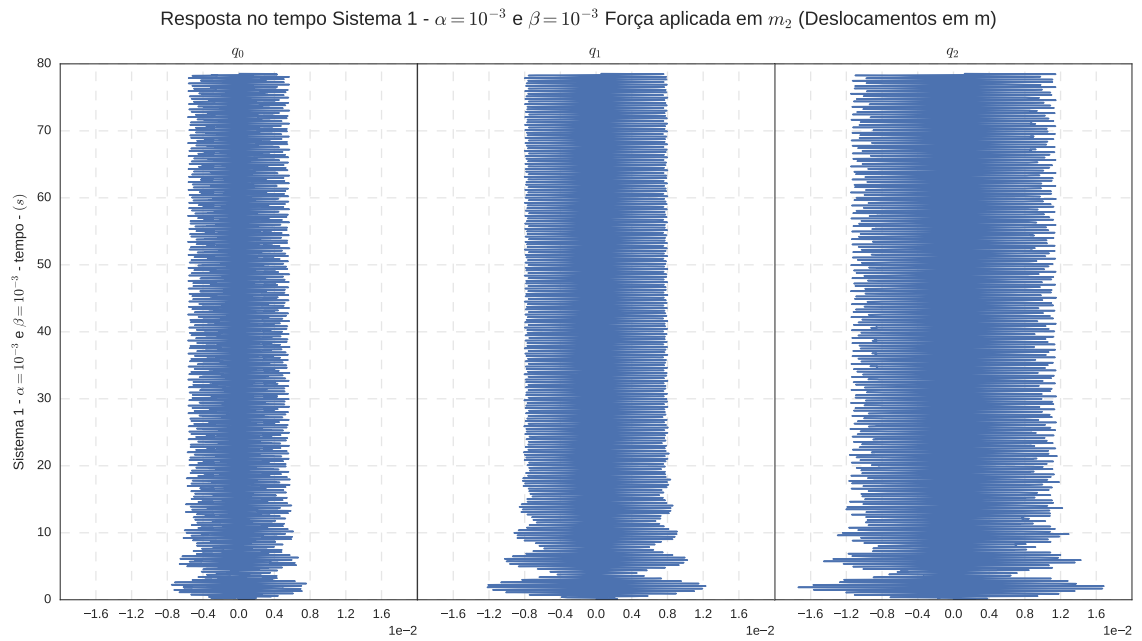


Figura 2.5: Resposta no tempo para a força  $F_1$  com  $N = 5000$ .




Figura 2.6: Resposta no tempo para a força  $F_2$  com  $N = 5000$ .

## 2.2 Adição do ruído

Conforme mostrado no item 2.1, a análise será feita para três diferentes níveis de ruído ( $SNR = 90, 50, 10$ ).

Temos então que o sinal utilizado para o projeto do filtro será:

$$y = y^{ideal} + n \quad (2.1)$$

onde  $n$  representa um ruído inserido no sinal.

Para calcularmos a amplitude do ruído inserido ' $n$ ' utilizaremos a eq. (2.2).

$$SNR = 20 \log_{10} \left( \frac{A_s}{A_n} \right) \rightarrow A_n = \frac{A_s}{10^{SNR/20}} \quad (2.2)$$

Abaixo (fig. 2.7, fig. 2.8 e fig. 2.9), são mostrados alguns resultados comparando o sinal puro e o sinal corrompido para um determinado nível de ruído.




Figura 2.7: Sinal puro e sinal corrompido para  $F_0$  e  $SNR = 90$ .




Figura 2.8: Sinal puro e sinal corrompido para  $F_0$  e  $SNR = 10$ .




Figura 2.9: Sinal puro e sinal corrompido para  $F_2$  e  $SNR = 10$ .

# Capítulo 3

## Projeto do Filtro Adaptativo

Para o algoritmo do filtro adaptativo CASTELLO e ROCHINHA [2] apresentam algumas opções que podem ser utilizadas. No caso do presente trabalho o algoritmo LMS (Least Mean Squares) foi escolhido.

### 3.1 Algoritmo LMS

Como mostrado por DINIZ [1], a configuração normalmente aplicada para identificação de sistemas com filtros adaptativos é mostrada na fig. 3.1. Nesta configuração temos que  $x(k)$  é o sinal de entrada, o sinal de saída do sistema que desejamos identificar é  $d(k)$  e a saída do filtro é  $y(k)$ . Estes sinais são comparados e o erro  $e(k)$  é calculado.




Figura 3.1: Configuração utilizada no algoritmo para filtros adaptativos.

Os valores de saída do filtro são calculados a partir de uma combinação linear dos seus coeficientes e do sinal de entrada, isto é:

$$y(k) = \sum_{i=0}^N w_i(k)x_i(k) = \mathbf{w}^T(k)\mathbf{x}(k) \quad (3.1)$$

onde  $\mathbf{w}(k)$  representa os coeficientes do filtro.

Para aplicações onde o vetor do sinal de entrada é uma versão atrasada do mesmo sinal, isto é:  $x_0(k) = x(k), x_1(k) = x(k-1), \dots, x_N(k) = x(k-N)$ ,  $y(k)$  é o resultado da aplicação de um filtro FIR ao sinal de entrada  $x(k)$ . Neste caso temos:

$$y(k) = \sum_{i=0}^N w_i(k)x(k-i) = \mathbf{w}^T(k)\mathbf{x}(k) \quad (3.2)$$

onde  $\mathbf{x}(k) = [x(k) \ x(k-1) \ \dots \ x(k-N)]^T$ .

O MSE (Mean Square Error) pode ser calculado como:

$$\xi(k) = E[e^2(k)] = E[d^2(k) - 2d(k)y(k) + y^2(k)] \quad (3.3)$$

Podemos reescrever a eq. (3.3):

$$\xi = E[d^2(k)] - 2\mathbf{w}^T \mathbf{p} + \mathbf{w}^T \mathbf{R} \mathbf{w} \quad (3.4)$$

onde  $p = E[d(k)\mathbf{x}(k)]$  é o vetor de correlação cruzada entre o sinal desejado e o sinal de entrada e  $\mathbf{R} = E[\mathbf{x}(k)\mathbf{x}^T(k)]$  é a matriz de correlação do sinal de entrada.

Se  $\mathbf{p}$  e  $\mathbf{R}$  são conhecidos, podemos encontrar a solução para  $\mathbf{w}$  que minimiza  $\xi$ .

O gradiente do MSE relativo aos coeficientes é:

$$\mathbf{g}_w = \frac{\partial \xi}{\partial \mathbf{w}} = \left[ \frac{\partial \xi}{\partial w_0} \frac{\partial \xi}{\partial w_1} \dots \frac{\partial \xi}{\partial w_N} \right] = -2\mathbf{p} + 2\mathbf{R}\mathbf{w} \quad (3.5)$$

Igualando o gradiente a zero encontramos o vetor de coeficientes que minimiza  $\xi$ :

$$\mathbf{w}_0 = \mathbf{R}^{-1}\mathbf{p} \quad (3.6)$$

Se boas estimativas  $\hat{\mathbf{p}}$  e  $\hat{\mathbf{R}}$  estão disponíveis podemos buscar uma solução:

$$\mathbf{w}(k+1) = \mathbf{w}(k) - \mu \hat{\mathbf{g}}_w(k) \quad (3.7)$$

$$= \mathbf{w}(k) + 2\mu(\hat{\mathbf{p}}(k) - \hat{\mathbf{R}}(k)\mathbf{w}(k)) \quad (3.8)$$

para  $k = 0, 1, 2, \dots$ , onde  $\hat{\mathbf{g}}_w(k)$  representa uma estimativa do gradiente da função objetivo com respeito aos coeficientes do filtro.

Uma possível solução é estimar o gradiente com estimativas instantâneas de  $\mathbf{R}$  e de  $\mathbf{p}$ .

$$\hat{\mathbf{R}}(k) = \mathbf{x}(k)\mathbf{x}^T(k) \quad (3.9)$$

$$\hat{\mathbf{p}}(k) = d(k)\mathbf{x}(k) \quad (3.10)$$

Temos então que a estimativa para o gradiente é:



$$\hat{\mathbf{g}}_{\mathbf{w}}(k) = -2e(k)\mathbf{x}(k) \quad (3.11)$$

Chegamos então ao algoritmo LMS em que a equação de atualização é:

$$\mathbf{w}(k+1) = \mathbf{w}(k) + 2\mu e(k)\mathbf{x}(k) \quad (3.12)$$

onde o fator de convergência  $\mu$  deve ser escolhido em um range que garanta a convergência.

## 3.2 Implementação do filtro

O filtro será implementado em Python como explicado abaixo.

Uma classe `class LMSFilter()` será criada para o filtro. Essa classe contém uma função de inicialização que possui como argumentos de entrada o número de coeficientes do filtro e o fator de convergência  $\mu$ . Na criação do filtro os coeficientes são igualados a zero como mostrado no código abaixo.

```
class LMSFilter(object):
    def __init__(self, Nc, mu):
        """
        Iniciar filtro com Nc coeficientes.
        """
        self.Nc = Nc
        self.mu = mu
        # valores iniciais para o filtro w = [0, 0, ..., 0]
        self.w = np.zeros(Nc)
```

O filtro possui uma função `predict(self, x)` que calcula a saída prevista para o filtro baseado no sinal de entrada  $\mathbf{x}$  ( $x(k)$ ). O cálculo é feito conforme a eq. (3.1):

$$y(k) = \sum_{i=0}^N w_i(k)x_i(k) = \mathbf{w}^T(k)\mathbf{x}(k) \quad (3.1 \text{ revisitada})$$

```
def predict(self, x):
    y = self.w @ x
    return y
```

A atualização do filtro é feita pela função `update(self, d, x)` considerando a eq. (3.12):

$$\mathbf{w}(k+1) = \mathbf{w}(k) + 2\mu e(k)\mathbf{x}(k) \quad (3.12 \text{ revisitada})$$

```

def update(self, d, x):
    """
    Atualizar filtro baseado no sinal de entrada  $x$ 
    e no valor desejado  $d$ .
    """
    y = self.w @ x
    e = d - y
    self.w += 2*self.mu * e * x

```

## Capítulo 4

# Resultados e Discussões

Assim como mostrado por CASTELLO e ROCHINHA [2], no caso analisado o fenômeno de anti-ressonância também não foi capturado pelo LMS.

## Capítulo 5

## Conclusões

# Referências Bibliográficas

- [1] DINIZ, P. S. *Adaptive filtering*. Springer, 1997.
- [2] CASTELLO, D. A., ROCHINHA, F. A. “An experimental assessment of transverse adaptive fir filters as applied to vibrating structures identification”, *Shock and Vibration*, v. 12, n. 3, pp. 197–216, 2005.

# Apêndice A

## Algumas Demonstrações